

UCLouvain

AssociationExplorer

Un système de détection d'associations dans les grandes données socio-économiques belges

Note d'avancement

Partie 1 : Couche sémantique

Carnot Dongmo Mbane
Promoteur : Prof. Cédric Heuchenne
UCLouvain

Table des matières

Table des matières	2
Avant-propos : objet de cette note	4
Chapitre 1 — État de l'art.....	5
1.1. Les données socio-économiques belges et leur exploitation	5
1.2. Solution proposée et public cible.....	5
1.3. Extraction depuis des documents PDF semi-structurés.....	5
1.4. Les grands modèles de langage pour l'exploration de schémas de données.....	6
Chapitre 2 — Couche sémantique : extraction, unification et pipeline.....	7
2.1. Difficultés et variabilité des formats sources	7
2.2. Pipeline d'extraction et de normalisation	7
2.2.1. Schémas de champs par enquête	8
2.2.2. Normalisation et enrichissement.....	8
2.3. Qualité de l'extraction	9
2.4. Le pipeline en cinq étapes : de l'extraction à l'application	9
2.4.1. Étape 1 — Unification	9
2.4.2. Étape 2 — Génération des embeddings.....	10
2.4.3. Étape 3 — Moteur de recherche sémantique	10
2.4.4. Étape 4 — Validation par modèle de langage	10
2.4.5. Étape 5 — Interface utilisateur	10
Chapitre 3 — Architecture du modèle de langage : deux approches coexistantes	11
3.1. Reformulation de l'objectif	11
3.2. L'approche RAG : architecture opérationnelle	11
3.2.1. Le modèle d'embeddings : multilingual-e5-large	11
3.2.2. La base vectorielle et la mesure de similarité.....	12
3.2.3. Évolution de la stratégie de recherche : de la pondération à la recherche simple	12
3.2.4. Le modèle de langage local : Llama 3.2 via Ollama	13
3.3. La piste du fine-tuning : architecture envisagée.....	13
3.4. Comparaison des deux approches.....	14
3.5. Gestion des défis techniques	15
3.5.1. Risque d'hallucination	15
3.5.2. Confusion sémantique	15
3.5.3. Stratégie générale de validation	15
3.6. Développement en cours : la boucle d'explication pédagogique des variables ...	15
Synthèse : bilan, limites et planning.....	21
4.1. Bilan global de cette partie	21
Points forts.....	21

Résultats attendus (inchangés depuis mars).....	21
Limites actuelles	21
Risques identifiés.....	22
4.2. Planning actualisé	22
4.3. Contributions principales de cette partie	23

Avant-propos : objet de cette note

Cette note constitue une mise à jour de la présentation de mi-parcours du 5 mars 2026. Elle porte exclusivement sur la première partie du mémoire, consacrée à la couche sémantique du système AssociationExplorer : l'état de l'art, l'extraction et la normalisation des métadonnées, et l'architecture de compréhension du langage naturel reposant sur un grand modèle de langage (LLM).

La seconde partie du mémoire, consacrée à la construction et à l'exploitation de graphes d'associations statistiques entre variables, n'est pas couverte ici. Elle fera l'objet d'une note d'avancement distincte, une fois que les travaux correspondants auront suffisamment progressé.

Par rapport à la présentation de mars, deux évolutions majeures structurent cette mise à jour. Premièrement, le périmètre des données traitées est passé de quatre à six enquêtes belges, avec l'intégration des bases IPCAL (données fiscales) et DEMOBEL (modèle de microsimulation). Deuxièmement, l'architecture du LLM a évolué de manière substantielle : alors que la présentation de mars envisageait un fine-tuning par LoRA d'un modèle Llama-3-8B comme solution unique, le travail réalisé depuis a privilégié une architecture de recherche augmentée par génération (RAG) combinant des embeddings sémantiques et un modèle de langage local non spécialisé. Les deux approches sont aujourd'hui documentées et comparées dans ce travail, la piste RAG constituant la solution opérationnelle actuelle.

Chapitre 1 — État de l'art

Statut [100 % — Inchangé depuis mars, complété sur le périmètre étendu]

1.1. Les données socio-économiques belges et leur exploitation

Les enquêtes socio-économiques constituent une source d'information précieuse pour comprendre les dynamiques sociales et économiques d'un pays. En Belgique, plusieurs grandes enquêtes structurent ce paysage statistique : l'enquête EU-SILC (Statistics on Income and Living Conditions), l'enquête EU-LFS (Labour Force Survey), l'enquête HBS (Household Budget Survey) et l'enquête HFCS (Household Finance and Consumption Survey). Ces quatre sources, déjà documentées dans la présentation de mars, ont depuis été complétées par deux bases supplémentaires, intégrées au même périmètre méthodologique : la base IPCAL, qui recense les informations issues des déclarations fiscales des contribuables belges, et le modèle DEMOBEL, un outil de microsimulation socio-fiscale utilisé pour évaluer l'impact de réformes politiques sur les ménages belges.

Ces six sources partagent un défi commun, déjà identifié en mars : leurs métadonnées, qui décrivent la signification de chaque variable statistique, sont dispersées dans des documents PDF volumineux (allant de 200 à plus de 600 pages), rédigées dans des codes techniques opaques (par exemple HY040G, PL031 ou A0270), et couvrent au total plus de 7000 variables une fois les six enquêtes combinées. Cette dispersion et cette opacité rendent l'exploitation de ces données difficile pour des utilisateurs non spécialistes du codage statistique, qu'il s'agisse de journalistes, de chercheurs en sciences sociales ou d'analystes de politiques publiques.

1.2. Solution proposée et public cible

La solution proposée, AssociationExplorer, reste fondée sur le même principe directeur qu'en mars : un système de détection d'associations statistiques piloté par un modèle de langage, permettant à l'utilisateur d'interroger le corpus de variables en langage naturel plutôt qu'en mémorisant des codes techniques. Le système doit pouvoir fonctionner dans les deux sens : à partir d'une question en langage naturel, il doit recommander les variables pertinentes ; à partir d'un code de variable, il doit en fournir une description compréhensible.

Le public cible n'a pas changé : journalistes d'investigation économique, chercheurs en sciences sociales, statisticiens et analystes de politiques publiques, qui partagent le besoin de naviguer rapidement dans des corpus de métadonnées complexes sans expertise technique préalable sur le codage de chaque enquête.

1.3. Extraction depuis des documents PDF semi-structurés

L'état de l'art sur l'extraction de texte depuis des documents PDF reste celui présenté en mars. Quatre bibliothèques Python ont été comparées empiriquement sur des échantillons représentatifs des quatre guides initiaux : PyPDF2, PDFMiner, pdfplumber et Camelot. PyPDF2 s'est révélé impropre à l'usage car il produisait un texte déstructuré, les

codes de variables étant parfois fragmentés caractère par caractère lors de l'extraction. PDFMiner offrait un contrôle plus fin mais au prix d'une complexité d'implémentation disproportionnée par rapport au gain de qualité obtenu. Camelot, spécialisé dans la détection de tableaux, échouait sur les structures pseudo-tabulaires de certains guides, où le texte est disposé en colonnes sans qu'une structure de tableau formelle soit présente dans le PDF lui-même.

Le choix s'est porté sur pdfplumber pour trois raisons. Premièrement, cette bibliothèque préserve l'ordre de lecture naturel des lignes, tel qu'un lecteur humain les percevrait, contrairement à PyPDF2 qui produisait par endroits des permutations de paragraphes. Deuxièmement, son interface de programmation reste simple et lisible, ce qui facilite la maintenance du code d'extraction sur la durée du projet. Troisièmement, elle respecte correctement les normes d'accessibilité PDF/UA utilisées par les organismes producteurs des guides (Eurostat, Banque Nationale de Belgique), ce qui améliore mécaniquement la qualité du texte extrait. Le taux de réussite empirique observé sur l'ensemble des essais est de l'ordre de 98 %, un résultat jugé suffisant pour ne pas justifier un changement d'outil lors de l'extension du périmètre aux deux nouvelles enquêtes.

1.4. Les grands modèles de langage pour l'exploration de schémas de données

Le champ de recherche sur l'utilisation des LLM pour la découverte et l'exploration de schémas de données (data discovery) demeure un axe pertinent de la revue de littérature. Deux familles d'approches structurent ce champ et ont depuis été explorées plus en profondeur dans le cadre de ce mémoire : d'une part, l'adaptation d'un modèle de langage généraliste à un domaine spécifique par fine-tuning, c'est-à-dire un réentraînement partiel sur un corpus spécialisé ; d'autre part, l'augmentation d'un modèle généraliste non modifié par une étape de recherche documentaire préalable, communément appelée RAG (Retrieval-Augmented Generation).

La présentation de mars envisageait principalement la première famille d'approches. Le travail réalisé depuis a permis d'explorer et de comparer les deux familles de manière approfondie, ce qui fait l'objet du chapitre 3 de cette note. Cette comparaison s'appuie notamment sur la littérature relative aux modèles d'embeddings de phrases (sentence-transformers) et aux bases vectorielles, qui constituent le socle technique de l'approche RAG.

Chapitre 2 — Couche sémantique : extraction, unification et pipeline

Statut [100 % pour les 4 enquêtes initiales — 100 % pour l'extension à 6 enquêtes]

2.1. Difficultés et variabilité des formats sources

La complexité structurelle des documents PDF source, déjà identifiée en mars, n'a pas varié avec l'ajout des deux nouvelles enquêtes. Les tableaux multi-colonnes sans bordures explicites, les en-têtes et pieds de page variables, ainsi que les encodages de caractères spéciaux (notamment pour les caractères accentués et les symboles monétaires) continuent de poser des défis pour une extraction automatisée fiable.

La variabilité entre enquêtes s'est en revanche enrichie avec l'ajout d'IPCAL et de DEMOBEL, chacune présentant ses propres conventions structurelles.

Enquête	Particularités structurelles
EU-SILC	5 patterns de variables : duales G/N (Gross/Net), registres RG_Z, séries PMH, séries PHD, format standard
EU-LFS	3 patterns : variables optionnelles marquées par astérisque, codes multiples pour une même question, format standard
HBS	Hiérarchie de classification COICOP à 5 niveaux d'imbrication
HFCS	Suffixes complexes (i pour imputation, SH pour sous-total household, \$x\$y pour les variables répétées par instrument financier), imputations multiples
IPCAL	Double système de codes (déclaration fiscale / IPCAL informatique), structure en «blocs» fiscaux (VAK), doublement des variables entre contribuant principal (A) et conjoint (B)
DEMOBEL	Organisation en feuilles thématiques (General, Wealth Tax, VAT, etc.), descriptions exclusivement en anglais avec spécification de type intégrée

2.2. Pipeline d'extraction et de normalisation

La méthodologie d'extraction repose, pour les quatre enquêtes initiales, sur une combinaison de pdfplumber pour l'extraction du texte brut et d'expressions régulières hiérarchiques pour la reconnaissance des patterns de variables propres à chaque enquête. Cette étape est suivie d'un nettoyage systématique (filtrage des éléments parasites tels que les numéros de page ou les répétitions d'en-tête, normalisation Unicode des caractères accentués) puis d'une reconstruction des descriptions qui s'étendent sur plusieurs lignes ou plusieurs pages.

Pour les deux nouvelles enquêtes, la méthodologie d'extraction diffère sensiblement, le format source n'étant plus un PDF mais directement un fichier Excel structuré. Pour IPCAL, le fichier source recense l'ensemble des variables de la déclaration fiscale belge

pour les exercices 2021 et 2022, avec un système de marquage des changements (variable nouvelle, supprimée, ou modifiée d'une année à l'autre). L'extraction a porté sur l'ensemble des variables valides, identifiées par un code conforme au format attendu, indépendamment de leur statut de changement, soit 5307 variables retenues sur les deux contribuants possibles (principal et conjoint). Pour DEMOBEL, le périmètre retenu se limite à la feuille «General» du fichier source, qui regroupe les variables socio-démographiques générales du modèle de microsimulation, soit 205 variables.

2.2.1. Schémas de champs par enquête

Chaque enquête dispose d'un schéma de métadonnées propre, hérité de la structure de son document ou fichier source. Le tableau suivant récapitule les schémas des six enquêtes après extraction.

Enquête	Nombre de champs	Champs principaux
EU-SILC	15	file_type, code, name, category, base_code, variant, topic, type, unit, period, short/long desc, values, mode
EU-LFS	10	code, desc, short/long, section, category, type, periodicity, codes
HBS	9	code, desc, file_type, category, format, values, notes, short/long
HFCS	11	doc_type, code, name, question, unit, period, coding, filtering, survey/tech def, notes
IPCAL	6	Code IPCAL, Code Déclaration, Contribuant, Statut, Description NL, Description FR
DEMOBEL	3	Name in Beamm (code), Variable Description, Specification (type)

2.2.2. Normalisation et enrichissement

La normalisation vise à produire, pour chaque variable et indépendamment de son enquête d'origine, deux niveaux de description : une description courte standardisée (de l'ordre de 100 à 150 caractères pour les enquêtes initiales) et une description longue enrichie au format Markdown. Pour IPCAL, la description longue combine les libellés néerlandais et français disponibles dans le fichier source, séparés par des marqueurs explicites. Pour DEMOBEL, la description longue combine le libellé anglais et la spécification de type.

Un traitement spécial continue d'être appliqué aux structures particulières identifiées en mars : les variables duales Gross/Net d'EU-SILC, les registres RG_Z, les séries PMH et PHD. À ces traitements s'ajoute, pour IPCAL, un traitement spécifique du doublement des variables entre contribuant principal et conjoint, chaque paire de codes étant traitée comme deux enregistrements distincts partageant la même description de base mais un identifiant de contribuant différent.

2.3. Qualité de l'extraction

La méthodologie de validation par échantillon Gold Standard, définie en mars pour les quatre enquêtes initiales, repose sur trois niveaux de contrôle : un contrôle syntaxique automatisé (vérification du format des codes et de la présence des champs obligatoires), un contrôle par échantillonnage (relecture manuelle d'un sous-ensemble de variables comparé au document source), et un contrôle statistique global (distribution des longueurs de description, détection des valeurs aberrantes).

Enquête	Variables	Échantillon validé	Conformité	Complétude
EU-SILC	337	20 (6 %)	100 %	93–100 %
EU-LFS	155	15 (9.7 %)	100 %	95–100 %
HBS	434	25 (5.8 %)	96 %	92–98 %
HFCS	571	20 (3.5 %)	98.5 %	94–99 %
Total initial	1497	80	98.6 %	93–99 %

Note : les effectifs par enquête ont légèrement varié par rapport à la présentation de mars (par exemple EU-LFS passe de 88 à 155 variables) suite à un raffinement du périmètre de variables retenues lors de l'unification finale ; ce point est documenté en section 2.4.

Pour les deux nouvelles enquêtes, le contrôle qualité a porté principalement sur le niveau syntaxique et statistique, le format source étant déjà structuré (fichier Excel) et ne nécessitant pas de validation d'extraction au sens propre. La principale vérification effectuée a porté sur la cohérence entre le nombre de lignes valides identifiées dans le fichier source et le nombre d'enregistrements produits après traitement du doublement des contribuants pour IPCAL.

Les erreurs résiduelles identifiées en mars restent d'actualité pour les quatre enquêtes initiales : un faible taux de descriptions tronquées lors des changements de page (moins de 5 %), de rares confusions entre variables très proches dans leur libellé (par exemple DA1000 et DA1000i dans HFCS), et des faux positifs provenant des tables des matières, désormais éliminés par un filtre dédié.

2.4. Le pipeline en cinq étapes : de l'extraction à l'application

Élément nouveau par rapport à la présentation de mars, le travail réalisé depuis a structuré l'ensemble du traitement en un pipeline reproductible de cinq étapes, chacune correspondant à un script Python autonome. Cette structuration constitue une contribution méthodologique en elle-même, dans la mesure où elle permet l'ajout de nouvelles enquêtes (comme IPCAL et DEMOBEL) sans modification du code existant pour les enquêtes déjà intégrées, par simple ajout de sections dédiées dans chacun des cinq scripts.

2.4.1. Étape 1 — Unification

Le premier script regroupe les six enquêtes en une base de données unique au format JSON, où chaque variable est représentée par un enregistrement structuré comprenant un identifiant unique, le code de la variable, l'enquête d'origine, une description courte et une description longue, ainsi que des métadonnées complémentaires (catégorie, sous-catégorie, période de référence). Pour chaque enquête, une fonction d'harmonisation dédiée transforme le schéma de champs propre à cette enquête vers le schéma unifié.

2.4.2. Étape 2 — Génération des embeddings

Le deuxième script transforme chaque description de variable en une représentation vectorielle numérique, ou *embedding*, à l'aide du modèle multilingual-e5-large. Ce modèle, présenté en détail au chapitre 3, produit des vecteurs de 1024 dimensions normalisés, indexés ensuite dans une base de données vectorielle (ChromaDB) configurée avec la métrique de similarité cosinus. Une collection distincte est créée pour chacune des six enquêtes, en complément d'une collection unifiée regroupant l'ensemble du corpus.

2.4.3. Étape 3 — Moteur de recherche sémantique

Le troisième script implémente la logique de recherche proprement dite, permettant deux modes d'interrogation : la recherche par question en langage naturel, qui retourne les variables les plus proches sémantiquement de la requête, et la recherche par code exact, qui retourne directement la fiche descriptive d'une variable connue. Ce script a fait l'objet d'évolutions méthodologiques importantes, documentées en détail dans le chapitre 3.

2.4.4. Étape 4 — Validation par modèle de langage

Le quatrième script fait intervenir un modèle de langage local (Llama 3.2, exécuté via Ollama) pour valider la pertinence des variables retournées par la recherche sémantique. Pour chaque variable candidate, le modèle indique si elle répond exactement à la question posée, si elle est partiellement pertinente, ou si elle est hors sujet, avec une justification courte. Ce script joue également un rôle d'explication pédagogique des variables, fonctionnalité enrichie en cours de développement et détaillée au chapitre 3.

2.4.5. Étape 5 — Interface utilisateur

Le cinquième script expose l'ensemble du système à travers une interface web construite avec Gradio, permettant à l'utilisateur de poser une question en langage naturel ou de rechercher un code de variable, de filtrer les résultats par enquête, et de visualiser les explications produites par le modèle de langage. Cette interface constitue le point d'entrée opérationnel du système pour les utilisateurs finaux visés par le mémoire (journalistes, chercheurs, analystes).

Chapitre 3 — Architecture du modèle de langage : deux approches coexistantes

Statut [100 % pour l'architecture RAG opérationnelle — Piste fine-tuning (piste) mais non implémentée]

3.1. Reformulation de l'objectif

L'objectif initial, formulé en mars, restait de développer un modèle de langage local capable de naviguer intelligemment dans les variables des enquêtes. La présentation de mars envisageait une unique voie pour y parvenir : le fine-tuning, c'est-à-dire le réentraînement partiel d'un modèle de langage généraliste sur un corpus spécialisé constitué des 1517 variables alors disponibles. Le travail réalisé depuis a conduit à explorer une seconde voie, le RAG (Retrieval-Augmented Generation), et à la mettre en œuvre de façon opérationnelle avant de revenir, en fin de chapitre, sur une comparaison argumentée des deux approches.

Cette section présente d'abord la voie RAG, qui constitue la solution actuellement opérationnelle du système AssociationExplorer, puis rappelle la voie du fine-tuning telle qu'envisagée en mars, avant de proposer une comparaison structurée des deux approches sur la base des critères qui importent pour ce mémoire.

3.2. L'approche RAG : architecture opérationnelle

L'approche RAG (Retrieval-Augmented Generation, ou génération augmentée par récupération) repose sur un principe distinct du fine-tuning : plutôt que de modifier les poids internes d'un modèle de langage pour qu'il « mémorise » un corpus spécialisé, elle laisse le modèle de langage inchangé et lui fournit, au moment de chaque requête, le contexte pertinent récupéré dynamiquement dans une base de connaissances externe. Le modèle de langage n'a donc pas besoin d'avoir « appris » les 7010 variables du corpus ; il reçoit, pour chaque question, les quelques variables les plus pertinentes déjà identifiées par un mécanisme de recherche sémantique, et formule sa réponse à partir de ce contexte.

3.2.1. Le modèle d'embeddings : multilingual-e5-large

Le cœur du mécanisme de recherche sémantique repose sur un modèle d'embeddings de phrases, multilingual-e5-large, développé par Microsoft Research. Ce modèle transforme tout texte, qu'il s'agisse d'une description de variable ou d'une question utilisateur, en un vecteur numérique de 1024 dimensions, de telle sorte que deux textes sémantiquement proches produisent des vecteurs proches dans cet espace, même s'ils ne partagent aucun mot commun. Le modèle a été choisi pour trois raisons : sa nature multilingue, indispensable compte tenu de la présence simultanée de descriptions en français, en néerlandais et en anglais dans le corpus ; sa performance, le plaçant parmi les meilleurs modèles multilingues du benchmark MTEB (Massive Text Embedding Benchmark) ; et son caractère local, c'est-à-dire qu'il peut être exécuté entièrement sur la

machine de l'utilisateur sans dépendre d'un service en ligne, ce qui répond à une préoccupation de confidentialité déjà identifiée en mars.

Architecturalement, multilingual-e5-large repose sur un Transformer encodeur de type XLM-RoBERTa, comportant 24 couches et environ 560 millions de paramètres. Chaque texte est d'abord découpé en unités lexicales (tokens), puis transformé par les 24 couches successives de mécanismes d'attention, avant que le vecteur correspondant au token spécial [CLS], censé résumer le sens de la phrase entière, ne soit extrait et normalisé. Le modèle a été entraîné par apprentissage contrastif sur environ un milliard de paires de textes multilingues, ce qui explique sa capacité à aligner des formulations équivalentes dans des langues différentes, une propriété directement exploitée pour faire correspondre une question posée en français à une description de variable rédigée en néerlandais dans le corpus IPCAL.

Une convention propre à ce modèle, et appliquée systématiquement dans l'implémentation, consiste à préfixer les textes à indexer par le mot-clé «passage:» et les questions de l'utilisateur par le mot-clé «query:». Cette asymétrie de préfixage permet au modèle de mieux aligner une question généralement courte avec un passage généralement plus long et descriptif.

3.2.2. La base vectorielle et la mesure de similarité

Les vecteurs produits par le modèle d'embeddings sont indexés dans ChromaDB, une base de données vectorielle persistante configurée pour utiliser la similarité cosinus comme métrique de comparaison. Cette métrique mesure l'angle entre deux vecteurs plutôt que leur distance brute, ce qui la rend insensible à la magnitude des vecteurs (après normalisation) et plus interprétable : un score de 0,92 signifie que deux textes partagent 92 % de similarité sémantique selon le modèle. Pour le corpus de ce mémoire, les scores de similarité observés pour des correspondances jugées pertinentes se situent typiquement entre 0,85 et 0,93.

Sept collections distinctes ont été créées dans la base vectorielle : une collection par enquête (EU-SILC, HFCS, EU-LFS, HBS, IPCAL, DEMOBEL) et une collection unifiée regroupant l'ensemble des 7010 variables, utilisée par défaut pour les recherches transversales.

3.2.3. Évolution de la stratégie de recherche : de la pondération à la recherche simple

Un développement méthodologique notable dans cette partie du travail concerne la stratégie de combinaison des résultats provenant des six enquêtes. Le corpus présente en effet un déséquilibre statistique important : la base IPCAL, avec 5307 variables, représente à elle seule 76 % du corpus total, contre seulement 2 % pour EU-LFS. Sans correction, une recherche sémantique sur la collection unifiée tend à retourner presque exclusivement des variables IPCAL, non pas parce qu'elles sont les plus pertinentes, mais parce qu'elles sont les plus nombreuses, un phénomène connu dans la littérature sous le nom de biais de taille (size bias).

Une première version du système a corrigé ce biais par une stratégie de pondération hybride, multipliant le score de similarité brut par un facteur dépendant de l'enquête d'origine et du type de question posée (recherche par code, mention explicite d'une enquête, vocabulaire fiscal belge, ou question générique). Cette stratégie, bien que fonctionnelle, a ensuite été retirée sur recommandation du promoteur du mémoire, au profit d'une recherche sémantique simple sans aucune pondération, le score de similarité cosinus brut étant utilisé directement pour le classement des résultats. Le système actuel reflète ce choix : la pondération par enquête a été intégralement supprimée du code de recherche.

3.2.4. Le modèle de langage local : Llama 3.2 via Ollama

Le modèle de langage proprement dit, chargé d'interpréter les résultats de la recherche sémantique et de formuler des réponses en langage naturel, est Llama 3.2, exécuté localement via Ollama. Contrairement à la piste de fine-tuning envisagée en mars, ce modèle est utilisé sans aucune modification de ses poids internes : il reçoit, à chaque requête, un contexte construit dynamiquement (les variables candidates retournées par la recherche sémantique, leurs descriptions, leurs scores de similarité) et produit sa réponse à partir de ce contexte, selon des instructions précises données dans le prompt.

Ce modèle remplit deux fonctions distinctes dans le pipeline. La première est une fonction de validation : pour une question donnée et un ensemble de variables candidates, il indique pour chacune si elle répond exactement à la question, si elle est partiellement pertinente, ou si elle est hors sujet, avec une justification courte. La seconde, plus récente, est une fonction d'explication pédagogique : pour chaque variable du corpus, il génère une description longue et accessible, destinée à un public non spécialiste, en complément d'une description heuristique générée par des règles de traitement de texte. Cette seconde fonction fait l'objet d'un développement encore en cours, documenté en section 3.4.

3.3. La piste du fine-tuning : architecture envisagée

La piste du fine-tuning, présentée en mars comme solution principale, reste documentée dans ce mémoire à titre de comparaison méthodologique, bien qu'elle n'ait pas été implémentée à ce stade. Cette section en rappelle les principes.

Le modèle de base candidat identifié en mars était Llama-3-8B, retenu pour son équilibre entre performance, taille et licence permettant un usage académique. La stratégie de fine-tuning envisagée reposait sur la technique LoRA (Low-Rank Adaptation), qui permet d'adapter un modèle de grande taille à un domaine spécifique en n'entraînant qu'un nombre restreint de paramètres supplémentaires (les matrices de rang faible insérées dans certaines couches), plutôt que l'ensemble des poids du modèle, ce qui réduit considérablement le coût de calcul et de mémoire de l'opération.

Le corpus d'entraînement envisagé combinait les variables enrichies du corpus unifié (1517 variables au moment de la présentation de mars) avec une stratégie d'augmentation de données visant à enseigner explicitement au modèle certaines

relations propres au domaine : les relations entre variables Gross et Net dans EU-SILC, les hiérarchies de classification COICOP dans HBS, et des synonymes ou reformulations courantes des libellés de variables. Le déploiement envisagé prévoyait un modèle exécuté localement, pour des raisons de confidentialité des données, avec une quantization à 4 bits pour réduire l'empreinte mémoire du modèle final.

3.4. Comparaison des deux approches

Les deux approches répondent au même objectif final mais reposent sur des principes fondamentalement différents, avec des implications distinctes en termes de coût, de flexibilité et de robustesse. Le tableau suivant synthétise cette comparaison.

Critère	RAG (approche opérationnelle)	Fine-tuning (approche envisagée)
Principe	Modèle de langage inchangé + recherche documentaire dynamique	Réentraînement partiel des poids du modèle sur le corpus
Coût de mise en œuvre	Faible : pas d'entraînement, infrastructure standard (CPU/GPU modeste)	Élevé : nécessite GPU dédié, temps d'entraînement, expertise en optimisation
Ajout de nouvelles variables	Immédiat : il suffit de générer l'embedding et de l'indexer	Coûteux : nécessite un nouveau cycle de fine-tuning pour intégrer le nouveau corpus
Transparence / explicabilité	Élevée : on peut inspecter les variables récupérées qui ont motivé la réponse	Faible : le savoir est diffus dans les poids du modèle, difficile à auditer
Risque d'hallucination	Réduit : le modèle répond à partir de variables réellement présentes dans le corpus	Présent : le modèle peut reproduire ou halluciner des codes proches mais inexistantes
Adaptation au vocabulaire métier	Dépend de la qualité du modèle d'embeddings pré-entraîné	Potentiellement supérieure si le fine-tuning est bien mené et le corpus suffisant
Maintenance dans le temps	Simple : mise à jour de l'index vectoriel uniquement	Complexe : chaque évolution du corpus implique un nouveau réentraînement
Maturité actuelle dans ce mémoire	Opérationnelle, testée sur les 6 enquêtes (7010 variables)	Non implémentée à ce stade

Cette comparaison ne tranche pas définitivement en faveur de l'une ou l'autre approche : chacune présente des avantages et des inconvénients qui dépendent du contexte d'usage. Le RAG présente l'avantage décisif, pour ce mémoire, de pouvoir intégrer de nouvelles enquêtes (IPCAL et DEMOBEL en l'occurrence) sans aucun coût de réentraînement, ce qui explique le choix de cette voie comme solution opérationnelle prioritaire. Le fine-tuning conserverait néanmoins un intérêt potentiel si l'objectif évoluait vers une compréhension plus fine et plus implicite du vocabulaire technique propre à

chaque enquête, un objectif qui pourrait être poursuivi dans une phase ultérieure du mémoire, en complément du RAG plutôt qu'en remplacement de celui-ci.

3.5. Gestion des défis techniques

Les trois défis techniques identifiés en mars restent pertinents et ont été traités, avec des solutions adaptées à l'architecture RAG finalement retenue.

3.5.1. Risque d'hallucination

Le risque qu'un modèle de langage invente une variable inexistante est structurellement réduit dans l'architecture RAG, puisque le modèle ne formule sa réponse qu'à partir des variables effectivement récupérées par la recherche sémantique. La fonction de recherche par code (`search_by_code`) opère par ailleurs un contrôle systématique d'existence du code recherché dans le dictionnaire des 7010 variables avant de renvoyer un résultat, garantissant qu'aucune variable inexistante ne peut être présentée comme valide.

3.5.2. Confusion sémantique

Le risque de confusion entre concepts proches (par exemple confondre une question sur les revenus locatifs avec les allocations familiales) est traité par la qualité intrinsèque du modèle d'embeddings multilingual-e5-large, dont l'entraînement contrastif sur un large corpus de paires question-réponse lui permet de distinguer des nuances sémantiques fines. Ce traitement diffère de la solution envisagée en mars (fine-tuning sur des requêtes annotées avec cas limites), mais répond au même besoin par un mécanisme différent : la qualité de représentation du modèle d'embeddings plutôt que l'apprentissage spécifique de cas limites.

3.5.3. Stratégie générale de validation

Le défi des variantes Gross/Net, ainsi que la validation globale de la pertinence des réponses, sont désormais traités par l'étape 4 du pipeline (validation par modèle de langage), qui examine chaque variable candidate dans son contexte et produit une justification explicite de sa pertinence ou de son absence de pertinence par rapport à la question posée. Une évaluation quantitative du système, menée sur un jeu de vingt questions annotées couvrant huit catégories thématiques (revenus, patrimoine, travail, logement, démographie, consommation, pauvreté, contexte COVID), a permis de mesurer un score de similarité moyen de 0,742, un MRR (Mean Reciprocal Rank) de 0,417 et un rappel à dix résultats de 0,533. Ces résultats, obtenus avant la suppression de la pondération hybride mentionnée en section 3.2.3, devront être recalculés sur la version actuelle du système pour rester pleinement représentatifs ; cette ré-évaluation constitue une tâche prioritaire identifiée pour la suite du travail.

3.6. Développement en cours : la boucle d'explication pédagogique des variables

Un développement substantiel, non anticipé dans la présentation de mars, est actuellement en cours : la mise en place d'une boucle systématique d'explication pédagogique de chaque variable du corpus. Cette section en détaille la motivation, la méthodologie complète, les mécanismes techniques mis en œuvre, et les premiers résultats obtenus.

3.6.1. Motivation et objectif

Les descriptions originales des variables, telles qu'extraites des guides PDF ou des fichiers Excel sources, restent rédigées dans un registre technique destiné aux praticiens des enquêtes statistiques. Une description comme «HY040G : Income from rental of a property or land (Gross)» ou «VAK X | inkomsten van kapitaal, RV ingehouden» suppose une familiarité avec le vocabulaire fiscal et statistique que le public cible du mémoire (journalistes, chercheurs en sciences sociales non quantitatives, analystes de politiques publiques) ne possède pas nécessairement. L'objectif de la boucle d'explication est de combler cet écart en produisant, pour chacune des 7010 variables du corpus, une description longue et accessible à un non-spécialiste, qui explique non seulement ce que mesure la variable, mais aussi comment elle s'interprète concrètement et dans quel contexte elle peut être utilisée.

Ce développement répond également à une exigence méthodologique explicite : les descriptions produites doivent être longues et détaillées, et non de simples résumés courts. Un résumé de deux ou trois mots ne permettrait pas à un utilisateur non averti de comprendre la portée d'une variable ; à l'inverse, une explication de plusieurs phrases, structurée et contextualisée, lui donne les moyens de juger par lui-même de la pertinence de la variable pour son usage.

3.6.2. Architecture de la boucle : deux générateurs complémentaires

La boucle d'explication combine deux mécanismes de génération de description, conçus pour se compléter plutôt que pour se concurrencer.

- Le générateur heuristique, entièrement fondé sur des règles de traitement de texte, ne fait appel à aucun modèle de langage. Il nettoie la description originale (suppression des marqueurs internes tels que [NL], [FR], VAK ou --info--), détecte la langue dominante de la description (français, néerlandais ou anglais) par comptage de mots-outils caractéristiques de chaque langue, infère le type probable de la variable (montant monétaire, pourcentage, date, comptage, catégorie, donnée géographique) par recherche de motifs lexicaux dans le code et la description, infère le niveau d'observation (ménage, individu ou déclaration fiscale), et assemble l'ensemble de ces éléments en une description structurée de plusieurs phrases en français, intégrant systématiquement le contexte de l'enquête d'origine.
- Le générateur par modèle de langage sollicite Llama 3.2 avec un prompt détaillé qui lui impose une structure en huit points obligatoires (présentés en section 3.6.4), produisant une explication encore plus riche que la version heuristique, avec un exemple concret chiffré et des précautions d'interprétation explicites.

La coexistence des deux générateurs présente un avantage pratique immédiat : la version heuristique, ne dépendant d'aucun appel réseau ni d'aucune latence de calcul, est disponible instantanément et sert de filet de sécurité si le modèle de langage local n'est pas disponible ou échoue sur une variable particulière. La version par modèle de langage, plus coûteuse en temps de calcul mais plus riche en contenu, constitue la description de référence lorsqu'elle est disponible.

3.6.3. Le générateur heuristique en détail

Le générateur heuristique repose sur quatre fonctions de détection appliquées successivement à chaque variable, avant assemblage de la description finale.

- La détection de langue compare les mots du texte source à deux ensembles de référence : un ensemble de mots-outils néerlandais (par exemple «de», «het», «berekening», «inkomen») et un ensemble de mots-outils français (par exemple «le», «revenus», «déclaration», «ménage»). La langue retenue est celle dont l'ensemble de référence obtient le score de correspondance le plus élevé, avec un seuil minimal de deux correspondances pour éviter une détection par excès de confiance sur un texte trop court.
- La détection du type de variable applique six familles d'expressions régulières au code, au nom et à la description de la variable : une famille pour les montants monétaires (mots-clés comme «income», «revenu», «montant», «loyer», «pension»), une pour les pourcentages et taux, une pour les informations temporelles (année, mois, trimestre), une pour les comptages (nombre d'heures, de semaines, de personnes), une pour les variables catégorielles (type, statut, indicateur), et une pour les données géographiques (région, commune, code postal).
- La détection du niveau d'observation distingue trois cas : le niveau ménage (mots-clés «household», «ménage», «huishouden», ou préfixe «H» dans certains codes EU-SILC), le niveau individuel (mots-clés «person», «personne», ou préfixe «P»), et le niveau fiscal, attribué automatiquement à toute variable de l'enquête IPCAL, qui relève par nature de la déclaration fiscale individuelle ou conjointe.
- Un score de qualité de la description originale, sur une échelle de 1 à 3, est enfin calculé à partir de la longueur cumulée des descriptions courte et longue disponibles dans la source : un score de 3 (description riche) au-delà de 300 caractères cumulés, un score de 2 (description correcte) entre 80 et 300 caractères, et un score de 1 (description pauvre) en deçà de 80 caractères. Ce score est conservé dans le fichier de sortie à titre indicatif, pour permettre une priorisation ultérieure des variables nécessitant un enrichissement manuel complémentaire si certaines descriptions s'avéraient insuffisantes même après traitement.

Sur la base de ces quatre détections, une description longue est assemblée selon une structure fixe en plusieurs phrases : une phrase d'identification de la variable et de son enquête d'origine, indiquant le type de valeur attendu ; une phrase reprenant l'intitulé

original de la variable, avec une traduction approximative si la langue détectée n'est pas le français ; une phrase intégrant la description originale nettoyée, lorsqu'elle existe et dépasse vingt caractères ; une phrase situant la variable dans la catégorie et la sous-catégorie de l'enquête ; une phrase de contexte sur le niveau d'observation ; un paragraphe de contexte sur l'enquête elle-même, rédigé une fois pour chaque enquête et réutilisé pour toutes ses variables ; une phrase sur la période de référence si elle est disponible ; et enfin deux phrases génériques mais informatives sur l'usage analytique typique de ce type de variable et les précautions d'interprétation à observer.

3.6.4. Le générateur par modèle de langage en détail

Pour chaque variable, quatre appels distincts sont adressés à Llama 3.2 via Ollama, correspondant à quatre combinaisons de longueur (courte ou longue) et de langue cible (langue d'origine de la variable ou français). Cette quadruple génération permet de disposer, pour chaque variable, d'une description courte et d'une description longue dans sa langue d'origine, ainsi que d'une description courte et d'une description longue traduites et adaptées en français, sans dépendre d'un service de traduction externe.

Le prompt destiné à la génération de la description longue impose explicitement au modèle une structure en huit points, reproduite ci-dessous dans son principe : présenter clairement ce que mesure la variable ; situer le contexte de l'enquête d'origine et la raison pour laquelle cette variable y figure ; préciser le type de valeur attendu et son unité de mesure ; fournir un exemple concret et parlant, ancré dans une situation réaliste de ménage ou de personne ; expliquer comment la variable peut être utilisée dans une analyse statistique ; signaler les précautions d'interprétation, notamment les valeurs manquantes ou les cas particuliers ; mentionner les relations possibles avec d'autres variables proches de la même enquête ; et conclure sur l'importance de cette variable pour la recherche socio-économique. Le modèle est explicitement instruit de produire un minimum de huit phrases et de ne rédiger aucune introduction ni conclusion superflue, afin que le texte produit soit directement exploitable sans retraitement.

À titre d'illustration, pour la variable HWUSUAL de l'enquête EU-LFS (nombre d'heures habituellement travaillées par semaine), le modèle produit une explication qui resitue la variable dans le contexte de la mesure du temps de travail en Europe, propose un exemple concret du type «si une personne travaille habituellement 38 heures par semaine répartie sur cinq jours, cette variable vaudra 38», signale que les valeurs peuvent varier en cas de temps partiel ou de double emploi, et relie la variable aux variables voisines HWACTUAL (heures effectivement travaillées pendant la semaine de référence) et HWOVERP (heures supplémentaires rémunérées).

Une attention particulière a été portée à la robustesse de ce mécanisme face aux échecs ponctuels du modèle de langage local, qui peut occasionnellement produire une réponse vide, tronquée ou hors format en raison de sa taille modeste comparée à des modèles propriétaires de plus grande capacité. Lorsqu'un appel au modèle échoue ou produit un résultat jugé insuffisant, la description heuristique correspondante est utilisée en repli,

garantissant qu'aucune variable ne se retrouve sans description exploitable dans le fichier final.

3.6.5. Organisation du traitement et format de sortie

La boucle traite les six enquêtes séquentiellement et indépendamment les unes des autres. Pour chaque enquête, un fichier Excel dédié est produit, comportant une feuille principale «Variables» avec, pour chaque variable, dix-sept colonnes : le code, l'enquête, la catégorie et la sous-catégorie d'origine, la période de référence, la langue détectée, le type de variable inféré, le niveau d'observation inféré, le score de qualité de la description originale, les deux descriptions originales (courte et longue), les deux descriptions heuristiques (courte et longue, en français), et les quatre descriptions produites par le modèle de langage (courte et longue, en langue d'origine et en français).

Une seconde feuille, intitulée «Résumé», est ajoutée à chaque fichier et synthétise des statistiques globales sur l'enquête traitée : le nombre total de variables, le nombre de descriptions générées avec succès par le modèle de langage contre le nombre de cas où le repli heuristique a été nécessaire, le temps de traitement total, ainsi que la distribution des variables selon leur score de qualité d'origine, leur type inféré et leur langue détectée. Cette feuille permet un contrôle qualité rapide de chaque fichier sans nécessiter une relecture exhaustive des plusieurs centaines ou milliers de lignes qu'il peut contenir.

Étant donné le volume de variables à traiter (jusqu'à 5307 pour la seule base de données IPCAL) et le temps de calcul non négligeable requis par chaque appel au modèle de langage, un mécanisme de point de contrôle (checkpoint) a été mis en place : les codes de variables déjà traités sont enregistrés au fur et à mesure dans un fichier texte dédié à chaque enquête, et le fichier Excel correspondant est sauvegardé à intervalles réguliers, tous les cinquante variables traitées. En cas d'interruption du traitement, qu'elle soit volontaire ou accidentelle, le programme reprend automatiquement à l'endroit où il s'est arrêté, sans perdre le travail déjà accompli ni retraiter inutilement les variables déjà décrites.

3.6.6. Premiers résultats et indicateurs de qualité

Au moment de la rédaction de cette note, le traitement est en cours d'exécution sur les six enquêtes. Les résultats les plus avancés concernent l'enquête EU-LFS, pour laquelle 105 variables sur 155 ont été traitées à ce stade. Les indicateurs de longueur des descriptions produites confirment le respect de l'exigence de richesse imposée à la boucle : la description longue heuristique atteint une longueur moyenne de 1696 caractères, avec un minimum observé de 1520 caractères, tandis que la description longue produite par le modèle de langage en français atteint une longueur moyenne de 2786 caractères, avec un minimum de 2216 caractères. Ces longueurs correspondent, en ordre de grandeur, à des paragraphes de huit à quinze lignes, conformes à l'exigence de descriptions longues plutôt que de résumés courts.

La distribution des types de variables détectés sur cet échantillon montre une répartition cohérente avec le contenu thématique de l'enquête EU-LFS, consacrée au marché du travail : trente-trois variables classées dans la catégorie «autre» (regroupant les variables

ne correspondant à aucun des six motifs explicitement recherchés), vingt-sept variables catégorielles, vingt-quatre variables temporelles, et treize variables de comptage, ce dernier groupe correspondant notamment aux nombreuses variables mesurant des durées en heures, semaines ou mois caractéristiques de cette enquête.

Deux incidents techniques ont été identifiés et corrigés au cours du développement de cette boucle, documentés en détail lors d'un échange de validation avec le code source. Le premier concernait la reprise du traitement sur les enquêtes EU-SILC et HFCS, pour lesquelles le fichier Excel de sortie se retrouvait vide après une interruption, en raison d'une relecture incorrecte des données déjà produites lors de la reprise. Le second concernait l'enquête EU-LFS, pour laquelle cinquante variables se trouvaient marquées comme traitées dans le fichier de point de contrôle sans avoir été effectivement écrites dans le fichier Excel, en raison d'un ordre d'opérations incorrect entre la mise à jour du point de contrôle et l'écriture du fichier de sortie. Ces deux anomalies ont été corrigées en modifiant l'ordre des opérations, de sorte que le point de contrôle ne soit désormais mis à jour qu'après confirmation de l'écriture réussie du fichier Excel, et en ajoutant un filtrage et un remappage explicite des colonnes lors de la relecture d'un fichier Excel existant.

3.6.7. Perspectives ouvertes par cette fonctionnalité

Au-delà de son objectif immédiat d'accessibilité pour l'utilisateur final, cette boucle d'explication pédagogique ouvre une perspective méthodologique intéressante pour la suite du mémoire. Les descriptions enrichies qu'elle produit, par leur volume, leur richesse et leur structuration homogène à travers les six enquêtes, constituent un corpus de qualité qui pourrait être réemployé comme matériau d'entraînement si la piste du fine-tuning, présentée et comparée au RAG en section 3.4, venait à être réactivée dans une phase ultérieure du travail. Cette boucle constitue ainsi un pont méthodologique potentiel entre les deux approches du chapitre 3, plutôt qu'un développement isolé au seul service de l'interface utilisateur.

Par ailleurs, les descriptions produites par cette boucle ont déjà été intégrées comme source de contexte privilégiée dans l'étape 4 du pipeline (validation par modèle de langage) et dans l'interface utilisateur de l'étape 5, qui interrogent désormais en priorité le cache de descriptions enrichies avant de solliciter à nouveau le modèle de langage à la volée, réduisant ainsi la latence perçue par l'utilisateur final lors de la consultation d'une variable déjà traitée par la boucle.

Synthèse : bilan, limites et planning

4.1. Bilan global de cette partie

Le tableau suivant reprend les points forts, les limites et les risques identifiés en mars, en les actualisant à la lumière du travail réalisé depuis.

Points forts

- Pipeline d'extraction robuste, avec une conformité de 98,6 % sur les quatre enquêtes initiales, désormais étendu sans régression à deux enquêtes supplémentaires de nature différente (fichiers Excel plutôt que PDF).
- Corpus unifié de 7010 variables normalisées, contre 1517 en mars, soit une multiplication par plus de quatre du périmètre couvert.
- Architecture en cinq étapes reproductible et modulaire, permettant l'ajout d'une nouvelle enquête par simple extension de chaque script, sans modification du code existant.
- Solution opérationnelle fonctionnelle de bout en bout : de la question en langage naturel jusqu'à la réponse validée par le modèle de langage, en passant par l'interface utilisateur Gradio.
- Modèle de langage exécuté localement (Llama 3.2 via Ollama, modèle d'embeddings multilingual-e5-large), garantissant la confidentialité des données traitées.
- Premiers résultats d'une boucle d'explication pédagogique des variables, produisant des descriptions longues et accessibles pour un public non spécialiste.

Résultats attendus (inchangés depuis mars)

- Gain de temps substantiel pour l'utilisateur final, de l'ordre de l'heure à la minute pour identifier une variable pertinente dans le corpus.
- Réduction des erreurs méthodologiques liées à une mauvaise interprétation des codes de variables.
- Démocratisation de l'accès aux données socio-économiques belges pour des publics non experts du codage statistique.

Limites actuelles

- L'évaluation quantitative du système (score moyen 0,742, MRR 0,417) a été menée avant la suppression de la pondération hybride et avant l'extension à six enquêtes ; elle doit être recalculée sur la version actuelle pour rester représentative.
- La boucle d'explication pédagogique des variables est encore en cours d'exécution sur l'ensemble du corpus au moment de la rédaction de cette note.

- La piste du fine-tuning, bien que documentée et comparée au RAG, n'a pas été implémentée ; la décision de la réactiver ou non dans une phase ultérieure reste ouverte.
- Les tests utilisateurs à grande échelle, envisagés en mars, n'ont pas encore été menés.
- Le chapitre consacré aux graphes d'associations statistiques entre variables n'a pas encore été développé et fera l'objet d'une note distincte.

Risques identifiés

- Performance du modèle de langage local par rapport à des alternatives propriétaires de plus grande taille, à mettre en balance avec l'exigence de confidentialité des données.
- Scalabilité de la base vectorielle et du futur graphe d'associations à mesure que le corpus s'enrichit (7010 variables actuellement, potentiellement davantage si d'autres sources sont intégrées).
- Adoption par les utilisateurs finaux, conditionnée par la simplicité perçue de l'interface, qui n'a pas encore été testée auprès du public cible.

4.2. Planning actualisé

Le planning ci-dessous actualise celui présenté en mars, en tenant compte du travail déjà réalisé et des tâches restant à accomplir pour clôturer cette première partie avant d'engager la seconde partie consacrée aux graphes d'associations.

Période	Objectif	Jalon attendu
Déjà réalisé	Extension du corpus à 6 enquêtes, pipeline 5 étapes opérationnel, suppression de la pondération hybride	Système RAG fonctionnel de bout en bout
En cours	Finalisation de la boucle d'explication pédagogique sur les 6 enquêtes	6 fichiers Excel complets avec descriptions enrichies
Court terme	Ré-évaluation quantitative du système sur la version actuelle (sans pondération, 6 enquêtes)	Métriques de précision/rappel actualisées
Moyen terme	Décision argumentée sur la réactivation ou non de la piste fine-tuning, à la lumière des descriptions enrichies disponibles	Note de décision méthodologique
Moyen terme	Démarrage du chapitre 4 (graphes d'associations) : construction, détection de communautés, visualisation	Prototype de graphe fonctionnel
Long terme	Expérimentations et tests utilisateurs, rédaction complète du mémoire	Mémoire finalisé

4.3. Contributions principales de cette partie

1. Pipeline d'extraction automatisée, étendu de quatre à six enquêtes sans régression sur le périmètre initial.
2. Dictionnaire sémantique unifié de 7010 variables, contre 1517 en mars.
3. Architecture RAG opérationnelle (embeddings multilingues + base vectorielle + modèle de langage local), constituant une alternative documentée et comparée à la piste de fine-tuning envisagée initialement.
4. Pipeline reproductible en cinq étapes, conçu pour faciliter l'intégration de sources de données supplémentaires.
5. Premiers résultats d'une boucle d'explication pédagogique des variables, en cours de finalisation.