

AssociationExplorer : a system to detect associations in large Belgian socioeconomic data

État d'avancement du mémoire - Point de mi-parcours

Carnot Dongmo Mbane

Enseignant : Prof. Cédric Heuchenne
Université Catholique de Louvain

5 mars 2026

Contexte et objectifs du mémoire

Problématique centrale

Les données socio-économiques belges (EU-SILC, LFS, HBS, HFCS) sont sous-exploitées :

- Métadonnées complexes dispersées dans des PDF de 200-600 pages
- Codes techniques opaques (HY040G, PL031, COICOP01111)
- **2500+ variables** sans outil de navigation adapté

Solution proposée : AssociationExplorer


Système de détection d'associations statistiques **piloté par LLM** :

- Interface en **langage naturel** (requêtes utilisateur)
- Recommandation intelligente de variables
- Visualisation par graphes de corrélation

Public cible

Journalistes, chercheurs en sciences sociales, statisticiens, analystes de

Architecture du système



Chapitre 1 : État de l'Art [100%]

Données socio-économiques en Belgique

- 4 enquêtes : EU-SILC (337 var), LFS (88 var), HBS (521 var), HFCS (571 var)
- Défis : codes cryptiques, multilinguisme, hétérogénéité formats

Extraction depuis PDF semi-structurés

- État de l'art : OCR, PyPDF2, pdfminer, Camelot
- **Choix justifié** : pdfplumber (98% taux réussite empirique)

LLM et exploitation des schémas de données

- Data Discovery : État de la recherche sur l'utilisation des LLM pour l'exploration de schémas.

Difficultés et Variabilité

Complexité structurelle :

- Tableaux multi-colonnes sans bordures
- Headers/footers variables, encodages spéciaux

Variabilité entre enquêtes :

- EU-SILC : 5 patterns (duales G/N, RG_Z, PMH, PHD, standard)
- EU-LFS : 3 patterns (optionnelles *, codes multiples, standard)
- HBS : hiérarchie COICOP à 5 niveaux
- HFCS : suffixes complexes (i, SH, \$x\$y), imputations multiples

Pipeline d'extraction

- **Méthodologie** : pdfplumber + regex hiérarchiques
- **Nettoyage** : filtrage parasites, normalisation Unicode
- **Reconstruction** : descriptions multi-lignes, sections structurées

Chapitre 2 : Couche sémantique (2/2) [100%]

Schémas par enquête :

- EU-SILC : 15 champs (file_type, code, name, category, base_code, variant, topic, type, unit, period, short/long desc, values, mode)
- EU-LFS : 10 champs (code, desc, short/long, section, category, type, periodicity, codes)
- HBS : 9 champs (code, desc, file_type, category, format, values, notes, short/long)
- HFCS : 11 champs (doc_type, code, name, question, unit, period, coding, filtering, survey/tech def, notes)

Normalisation et enrichissement :

- Short descriptions standardisées (100-150 car)
- Long descriptions en Markdown (8 sections pour EU-SILC)
- **Traitement spécial** : variables G/N, registres RG_Z, séries PMH/PHD
- Format Excel multi-feuilles + CSV + (JSON optionnel)

Qualité de l'extraction [95% - À formaliser]

- **Gold Standard** : échantillons validés manuellement
- **Trois niveaux** : syntaxique, échantillonnage, statistique

Résultats obtenus

Enquête	Variables	Échantillon	Conformité	Complétude
EU-SILC	337	20 (6%)	100%	93-100%
EU-LFS	88	15 (17%)	100%	95-100%
HBS	521	25 (4.8%)	96%	92-98%
HFCS	571	20 (3.5%)	98.5%	94-99%
Total	1517	80	98.6%	93-99%

Erreurs résiduelles identifiées

- Descriptions tronquées (changements de page) : 5%
- Variables similaires (DA1000 vs DA1000i) : rares
- Faux positifs tables des matières : éliminés

Chapitre 3 : LLM spécialisé (1/3) [0% - À développer]

Objectif

Développer un **LLM local fine-tuné** pour navigation intelligente dans les variables

Architecture du modèle

Modèle de base candidat :

- Llama-3-8B, PyTorch
- Critères : performance, taille, licence open-source

Stratégie de fine-tuning :

- LoRA (Low-Rank Adaptation) pour efficacité
- Corpus : 1517 variables enrichies + descriptions
- Augmentation : relations G/N, hiérarchies COICOP, synonymes

Déploiement :

- Modèle local (confidentialité données sensibles)
- Quantization 4 bit pour performance

Mode 1 : Requête → Variables

- **Input** : *"Quelles variables concernent les revenus locatifs?"*
- **Output attendu** :
 - HY040G (revenus locatifs bruts)
 - HY040N (revenus locatifs nets)
 - **NE PAS suggérer** : HY090G (intérêts/dividendes)
 - **NE PAS confondre avec** : HY050N (allocations familiales)
- **Justification** : "HY040G/N mesurent spécifiquement les revenus de location immobilière"

Mode 2 : Variable → Description

- **Input** : *"Qu'est-ce que PL073?"*
- **Output attendu** :
 - Source : EU-SILC, P-File (Personal Data)
 - Nom : Duration of unemployment
 - Type : Quantitative continue, Annual
 - Description : Durée totale en mois de la période de chômage en cours
 - Format : 0-99 mois (-1 = Missing)

Chapitre 3 : Gestion des défis techniques

Défi 1 : Hallucination

- Risque : inventer des variables inexistantes (HY999Z)
- **Solution** : Validation systématique contre dictionnaire (1517 variables)
- Reject sampling : seules les variables validées sont retournées

Défi 2 : Confusion sémantique

- Risque : "revenus" → suggérer allocations familiales (HY050N)
- **Solution** : Fine-tuning sur 100+ requêtes annotées avec cas limites
- Embeddings sémantiques précis (sentence-transformers)

Défi 3 : Variantes Gross/Net

- Risque : suggérer HY040G alors que contexte demande Net
- **Solution** : Analyse du contexte analytique
- Justification explicite : "Gross = revenu primaire, Net = revenu disponible"

3.4. Métriques d'évaluation

Précision, Rappel, F1-Score, Taux err sémantique (obj : > 95% précision)

Objectif

Visualiser les associations statistiques entre variables suggérées par le LLM

4.1. Construction

- Nœuds = variables LLM
- Arêtes = corrélations
- Poids = force association

4.2. Détection communautés

- Algorithme Louvain/Leiden
- Clusters thématiques
- Validation LLM

4.3. Analyse topologique

- Centralité (variables pivots)
- Modularité sous-graphes
- Chemins sémantiques

4.4. Visualisation

- Force-directed layout
- Filtres dynamiques LLM
- Export sous-réseaux

Intégration LLM Graphe

LLM suggère variables → Graphe calcule associations → Utilisateur explore → Questions de suivi au LLM

Workflow utilisateur complet

Cas d'usage : Journaliste - Précarité énergétique en Wallonie

- ❶ **Requête** : *"Analyser la précarité énergétique en Wallonie"*
 - ❷ **LLM suggère** :
 - HY020 (revenu disponible ménage)
 - HH031 (capacité à chauffer logement)
 - COICOP045 (dépenses électricité/gaz)
 - HC040 (humidité logement)
 - DB040 (région → filtrer Wallonie)
 - ❸ **Graphe** : Corrélations entre variables (revenus faibles dépenses énergie élevées)
-
- ❶ Validation LLM : 100+ requêtes annotées, tests A/B, métriques précision/rappel
 - ❷ Tests utilisateurs : Journalistes, chercheurs, statisticiens : utilité, utilisabilité, temps gagné

Qualité globale : Bilan

Points forts

- Pipeline extraction robuste (98.6% conformité)
- 1517 variables normalisées
- Documentation enrichie (short/long)
- Méthodologie reproductible
- LLM local (confidentialité)
- Fine-tuning spécialisé

Résultats attendus

- Gain temps : heures → minutes
- Réduction erreurs méthodologiques

Limites

- Couplage formats actuels
- Validation manuelle partielle
- Descriptions tronquées (<5%)
- LLM à développer
- Corpus annotations nécessaire
- Tests utilisateurs à grande échelle

Risques

- Performance LLM vs taille
- Scalabilité graphe (1517 nœuds)
- Adoption utilisateurs (simplicité interface)

Planning

Période	Objectif	Jalons
S1-2	Chap 2.4 + Choix modèle LLM	Éval formalisée, Benchmark
S3-4	Fine-tuning LLM + Corpus	Modèle v1 opérationnel
S5-6	Chap 4 Graphes + Intégration	Prototype fonctionnel
S7-8	Chap 5 Expérimentations + Rédaction	Tests utilisateurs, Mémoire complet

Contributions principales

- 1 Pipeline extraction automatisée ()
- 2 Dictionnaire sémantique 1517 variables ()
- 3 LLM spécialisé navigation métadonnées
- 4 Visualisation graphes associations
- 5 Outil AssociationExplorer complet

Merci de votre attention. Questions ?